In [1]:

```
import pandas as pd
import numpy as np

from sklearn.preprocessing import MinMaxScaler
from sklearn.feature_selection import VarianceThreshold
from sklearn.decomposition import PCA
from sklearn.linear_model import LinearRegression
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_squared_error, mean_absolute_error
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
%matplotlib notebook
```

In [2]:

```
data = pd.read_csv('./googleplaystore.csv')
data = data.assign(Installs_numeric=0)
data.head(3)
```

Out[2]:

	Арр	Category	Rating	Reviews	Size	Installs	Туре	Price	Content Rating	
0	Photo Editor & Candy Camera & Grid & ScrapBook	ART_AND_DESIGN	4.1	159	19M	10,000+	Free	0	Everyone	
1	Coloring book moana	ART_AND_DESIGN	3.9	967	14M	500,000+	Free	0	Everyone	D€
2	U Launcher Lite – FREE Live Cool Themes, Hide	ART_AND_DESIGN	4.7	87510	8.7M	5,000,000+	Free	0	Everyone	
4										•

In [3]:

```
print('%d Total amostras'%len(data))
data = data.dropna()
print('%d Total amostras (s/ NaN)'%len(data))
```

10841 Total amostras 9360 Total amostras (s/ NaN)

In [4]:

```
data.groupby(['Category']).agg('count')
category = {'1.9': 0, 'ART_AND_DESIGN': 1, 'AUTO_AND_VEHICLES': 2, 'BEAUTY': 3, 'BOOKS_AND_data['categoryID'] = data['Category'].map(lambda i: category[i])
```

```
In [5]:
```

```
data.groupby(['Type']).agg('count')
type = {'0': 0, 'Free': 1, 'Paid': 2 }
data['typeID'] = data['Type'].map(lambda i: type[i])
```

In [6]:

```
data.groupby(['Content Rating']).agg('count')
type = {'Adults only 18+': 0, 'Everyone': 1, 'Everyone 10+': 2, 'Mature 17+': 3, 'Teen': 4,
data['contentRatingID'] = data['Content Rating'].map(lambda i: type[i])
```

In [7]:

```
data['installsNumeric'] = data['Installs'].map(lambda i: int(i.replace('+','').replace(',',')
```

In [8]:

```
data['priceNumeric'] = data['Price'].map(lambda i: float(i.replace('$','').replace('.',''))
```

In [9]:

```
data['reviewsNumeric'] = data['Reviews'].map(lambda i: int(i))
```

In [10]:

In [11]:

Out[11]:


In [12]:

```
predictions = model.predict(test_x)
predictions
```

Out[12]:

In [13]:

```
plt.figure(figsize=(5,5))
plt.xlabel("Real")
plt.ylabel("Predição")
plt.plot([0,1],[0,1],c='k')
plt.scatter(test_y, predictions);
```



In [14]:

```
print("MAE: %.3f"%(mean_absolute_error(test_y, predictions)))
```

MAE: 29070431.979

In []:

```
# Conclusões
# Foi escolhido um Dataset de downloads de Apps na Play Store
# Usando CRISP-DM bscamos resolver um problema conhecido, criando um modelo que
# confrontasse os dados com o Número de downloads, utilizando uma técnica de regressão para
# Foi necessário normalizar quase todos os campos, pois quase todos eram Strings com símbol
# O resultado foi um gráfico vertifical, com quase todos os valores variando entre 0 e 0.1
# Ao chegar nesse resultado, realizamos uma nova iteração e tentamos mudar nossa analise de
# no intuito de analisar esses dados em forma de clusters, porém tivemos problemas na exibi
# voltar para o resultado inicial.
```